Motion-id: Comparação entre os modelos Random Forest e SVM

1st Gustavo Lima Jatobá Leite
Afya Maceió (UNIMA)
Ciência da Computação
Maceió, Brasil

2nd Ryan Guimarães Cassimiro
Afya Maceió (UNIMA)
Ciência da Computação
Maceió, Brasil
ryan.cassimiro@alunos.afya.com.br

3rd Wanessa Angélica de Araújo Costa
Afya Maceió (UNIMA)
Ciência da Computação
Maceió, Brasil
wanessa.c@alunos.afya.com.br

4th Ygor Gabriel Brandão Menezes Lima
Afya Maceió (UNIMA)
Ciência da Computação
Maceió, Brasil

Resumo—O reconhecimento de atividades humanas (HAR) permite inferir movimentos e posturas a partir de sensores inerciais. Este artigo compara Support Vector Machine (SVM) e Random Forest na classificação de seis atividades do UCI HAR, composto por 10.299 janelas de 30 participantes e 561 características por janela. Preservou-se a divisão oficial entre treinamento (7.352 janelas) e teste (2.947), com validação cruzada *GroupKFold* de cinco partições agrupadas por participante. Os hiperparâmetros foram selecionados pelo F1-score macro antes da avaliação final. No teste oficial, o SVM linear ($C = 0{,}1$) obteve 96,17% de acurácia e 96,15% de F1 macro, contra 92,40% e 92,17% do Random Forest, respectivamente. Na matriz de confusão do SVM, o principal erro ocorreu entre Sentado e Em pé, enquanto no Random Forest se destacaram características de aceleração gravitacional e orientação. Os resultados indicam maior desempenho preditivo do SVM nas configurações avaliadas, sem pressupor generalização para outros conjuntos de dados.

Index Terms—reconhecimento de atividades humanas, UCI HAR, SVM, Random Forest, GroupKFold, classificação

I. Introdução

O uso de acelerômetros e giroscópios em smartphones permite registrar variações de aceleração e velocidade angular durante atividades cotidianas. Entretanto, os sinais desses sensores não identificam diretamente a ação executada: é necessário extrair características e utilizar métodos capazes de associar padrões sensoriais a classes previamente definidas. Esse processo, denominado reconhecimento de atividades humanas (*Human Activity Recognition* — HAR), pode apoiar aplicações de acompanhamento de atividade física, assistência e sistemas sensíveis ao contexto.

Um desafio central é reconhecer atividades realizadas por pessoas que não participaram do treinamento. Quando janelas do mesmo voluntário aparecem simultaneamente no treino e na validação, o desempenho estimado pode ser otimista, pois padrões pessoais podem ser explorados pelo classificador. Por esse motivo, a separação por indivíduo é um componente essencial do protocolo experimental deste estudo.

Questão de pesquisa: entre Support Vector Machine (SVM) e Random Forest, qual classificador apresenta melhor desempenho ao identificar seis atividades humanas em participantes reservados para teste, considerando métricas de classificação e os tempos computacionais registrados?

O objetivo geral é comparar esses dois algoritmos usando as características inerciais do UCI HAR [1], [2]. Como objetivos específicos, busca-se: (i) caracterizar o dataset e suas partições; (ii) preparar os modelos e selecionar hiperparâmetros por validação cruzada agrupada; (iii) medir acurácia, precisão, revocação e F1 macro; (iv) examinar confusões entre classes; e (v) analisar a importância das características do Random Forest e os tempos observados de execução.

A comparação é conduzida com a divisão oficial do dataset e parâmetros definidos antes do uso da partição de teste. Após os trabalhos relacionados, apresentam-se dados e metodologia, modelos, resultados experimentais, discussão e conclusão.

II. Trabalhos Relacionados

Anguita *et al.* [1] divulgaram um conjunto público para reconhecimento de atividades humanas a partir de sensores inerciais de smartphone. Os registros e as características extraídas foram disponibilizados no repositório UCI [2], permitindo a comparação de técnicas sobre a mesma base de dados e com uma separação oficial entre participantes de treinamento e teste.

Na formulação de Cortes e Vapnik [3], máquinas de vetores de suporte buscam fronteiras de decisão com margens adequadas, definidas em função dos exemplos próximos à separação. Dependendo do kernel, a fronteira pode ser linear ou não linear. Breiman [4] apresentou o Random Forest, que combina decisões de múltiplas árvores e utiliza aleatoriedade para diversificar seus classificadores.

Essas abordagens diferem tanto na construção da função de decisão quanto no custo e na interpretação do modelo. Enquanto o SVM opera sobre separações no espaço de atributos, o Random Forest agrega decisões de árvores e fornece medidas globais de importância das características.

Tabela I

COMPOSIÇÃO DAS PARTIÇÕES OFICIAIS DO UCI HAR.

Partição	Janelas	Participantes	Atributos
Treinamento	7.352	21	561
Teste	2.947	9	561
Total	10.299	30	561

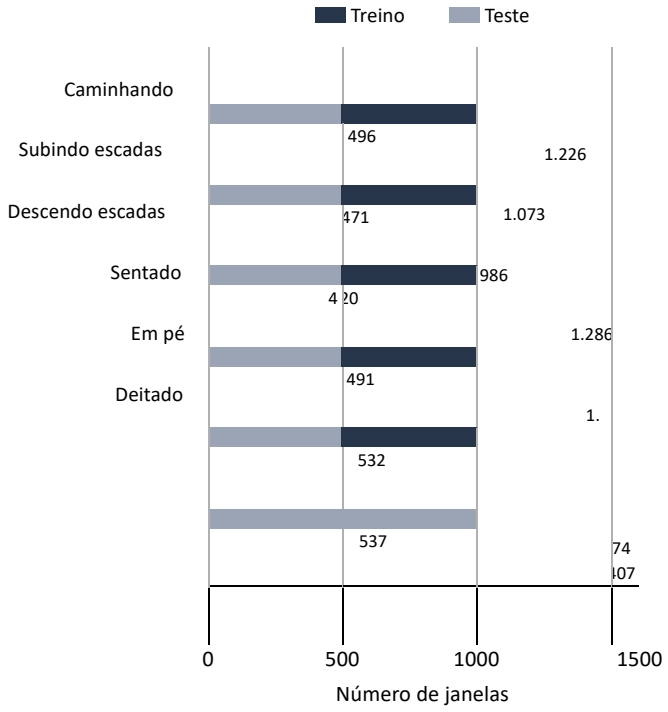


Figura 1. Distribuição de janelas por atividade no treino e no teste oficiais.

Neste trabalho, ambas as implementações utilizam o scikitlearn [5]. A contribuição experimental está na comparação sob um protocolo comum, com validação por participante, avaliação em conjunto reservado e análise dos erros e atributos relevantes.

III. CONJUNTO DE DADOS E METODOLOGIA

A. Dataset e divisão oficial

Foi empregado o *Human Activity Recognition Using Smartphones* (UCI HAR) [1], [2], obtido com 30 voluntários entre 19 e 48 anos que usaram smartphones Samsung Galaxy S II na cintura. O acelerômetro e o giroscópio produziram sinais em três eixos, amostrados a 50 Hz e segmentados em janelas de 2,56 s com 50% de sobreposição. As seis atividades são Caminhando, Subindo escadas, Descendo escadas, Sentado, Em pé e Deitado.

Cada janela possui 561 características numéricas previamente extraídas nos domínios do tempo e da frequência. Assim, o experimento classifica essas características e *não* inclui extração em tempo real de sinais brutos. O dataset reúne 10.299 janelas distribuídas em 7.352 de treinamento e 2.947 de teste. As partições oficiais, indicadas na Tabela I, contêm participantes distintos: 21 no treinamento e nove no teste.

A Fig. 1 apresenta a quantidade de janelas de cada atividade nas partições originais. Os identificadores dos voluntários foram utilizados para construir as divisões da avaliação, sem serem fornecidos como características de entrada dos classificadores.

B. Validação agrupada e seleção de parâmetros

A busca de hiperparâmetros foi realizada *somente* na partição oficial de treinamento, mediante validação cruzada *GroupKFold* com cinco folds [6]. Em cada divisão, todas as janelas de um participante são atribuídas integralmente ao treino ou à validação. Isso impede sobreposição de indivíduos na mesma rodada e reduz o risco de estimativas artificialmente elevadas por dependência entre janelas.

O critério de seleção foi o F1-score macro, calculado com o mesmo peso para cada atividade. Após a busca, os parâmetros selecionados foram registrados em JSON, usados no treinamento final com as 7.352 janelas e avaliados nas 2.947 janelas do conjunto oficial de teste. Não se fez nova seleção de hiperparâmetros com base nas observações desse teste.

C. Métricas de desempenho

Foram registradas acurácia, precisão macro, revocação macro e F1-score macro, além dos tempos de ajuste e predição. Para cada classe c, precisão (P_c) e revocação (R_c) correspondem às razões entre verdadeiros positivos e, respectivamente, previsões positivas ou exemplos positivos reais. O F1 por classe é a média harmônica entre as duas medidas:

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \qquad F1_{\text{macro}} = \frac{1}{6}\sum_{c=1}^{6} F1_c \,. \tag{1}$$

As médias macro evitam que as classes com maior quantidade de janelas dominem a avaliação. A matriz de confusão, por sua vez, permite observar a frequência e a direção dos erros entre atividades.

IV. MODELOS DE APRENDIZADO DE MÁQUINA

A. Support Vector Machine

O SVM [3] foi implementado com SVC no *Pipeline* do scikitlearn [5], antecedido por StandardScaler. A padronização é ajustada apenas sobre o subconjunto de treino de cada fold, para evitar que as estatísticas da validação influenciem o préprocessamento. O parâmetro C regula a penalização de erros; o kernel define a representação usada para separar as classes. Para o kernel RBF, γ controla a escala da função de similaridade.

A busca em grade avaliou 12 configurações: três valores de C com kernel linear e combinações de C e γ com kernel RBF. A maximização do F1-score macro selecionou kernel linear com C

=0,1. Essa configuração foi congelada antes da avaliação no teste oficial.

B. Random Forest

O Random Forest [4] combina árvores de decisão treinadas com mecanismos de aleatoriedade; as previsões de classe são agregadas para produzir a classificação final. A busca do projeto considerou quantidade de árvores, profundidade máxima e número de características avaliadas nas divisões das árvores.

A configuração selecionada foi 100 árvores, profundidade máxima 10 e max_features=sqrt, com semente aleatória 42. A análise adicional utilizou a importância global baseada na redução média de impureza (feature_importances_), calculada com o modelo ajustado somente sobre a partição de treinamento. Essa medida expressa o uso relativo dos atributos no conjunto de árvores, sem identificar efeitos causais.

Tabela II

VALIDAÇÃO CRUZADA EM CINCO FOLDS (MÉDIA ± DP).

Métrica	SVM (%)	RF (%)
Acurácia	93,27±4,39	92,09±4,52
F1 macro	93,11±4,83	92,07±4,60

Nota: desvio padrão (DP) expresso em pontos percentuais.

Tabela III

RESULTADOS DO SVM EM CADA FOLD DE VALIDAÇÃO.

Fold	Janelas de validação	Acurácia (%)	F1 macro (%)
1	1.420	87,32	85,86
2	1.420	90,85	91,33
3	1.417	98,09	98,00
4	1.410	96,81	96,75
5	1.685	93,29	93,60

C. Procedimento experimental

Os dois modelos utilizaram as mesmas 561 características e a divisão oficial dos participantes. Os parâmetros resultantes da validação cruzada foram recuperados dos relatórios salvos, sem repetir a busca no holdout. A avaliação final produziu relatórios JSON/CSV com métricas e tempos; análises complementares geraram matrizes de confusão e gráficos de características. Dessa maneira, os resultados foram preservados como artefatos verificáveis do experimento.

V. RESULTADOS EXPERIMENTAIS

A. Validação cruzada

As médias obtidas nos cinco folds do *GroupKFold* estão na Tabela II. O SVM alcançou acurácia média de 93,27% e F1 macro de 93,11%, enquanto o Random Forest registrou 92,09% e 92,07%. No SVM, a acurácia variou de 87,32% a 98,09% entre folds, indicando que a composição dos grupos influencia o desempenho observado.

A busca de parâmetros durou 30,69 s no SVM e 410,5 s no Random Forest. Essas durações descrevem as execuções registradas, não uma comparação universal de eficiência, pois dependem do ambiente e das configurações de cada busca.

Para mostrar a variabilidade ocultada pela média, a Tabela III detalha os resultados do SVM em cada fold. A validação incluiu subconjuntos de tamanhos diferentes, pois os participantes foram mantidos intactos durante a separação. O primeiro fold apresentou o menor F1 macro (85,86%), enquanto o terceiro atingiu 98,00%. A amplitude observada reforça a importância de não avaliar o modelo com uma única partição aleatória de janelas.

B. Avaliação final dos dois modelos

A avaliação oficial utilizou os mesmos 2.947 registros reservados, pertencentes a nove participantes ausentes da partição de treino. A Tabela IV apresenta os resultados finais. O SVM superou o Random Forest nas quatro métricas de classificação, com diferença de 3,77 pontos percentuais na acurácia e de 3,98 pontos percentuais no F1 macro.

Tabela IV

RESULTADOS DOS MODELOS NO HOLDOUT OFICIAL.

Métrica	SVM	Random Forest
Acurácia (%)	96,17	92,40
Precisão macro (%)	96,34	92,61
Revocação macro (%)	96,07	92,02
F1 macro (%)	96,15	92,17
Treinamento final (s)	0,3037	4,1651
Predição no teste (s)	0,1783	0,0125

Tabela V

MÉTRICAS DO SVM POR ATIVIDADE NO TESTE OFICIAL.

Atividade	Prec.	Rev.	F1	*N*
Caminhando	0,957	0,998	0,977	496
Subindo escadas	0,964	0,962	0,963	471
Descendo escadas	0,993	0,950	0,971	420
Sentado	0,960	0,888	0,923	491
Em pé	0,907	0,966	0,935	532
Deitado	1,000	1,000	1,000	537

Tabela VI PRINCIPAIS ERROS DO SVM NO TESTE OFICIAL.

Classe real	Classe prevista	Casos
Sentado	Em pé	53
Em pé	Sentado	18
Subindo escadas	Caminhando	16
Descendo escadas	Subindo escadas	15
Descendo escadas	Caminhando	6

O tempo de ajuste final foi menor para o SVM, enquanto o de predição registrado foi menor para o Random Forest. Como os tempos provêm de medições pontuais, eles não fundamentam conclusões gerais de velocidade entre algoritmos.

C. Matriz de confusão do SVM

A análise complementar reproduziu a acurácia armazenada para o holdout (0,9617). No total, 2.834 das 2.947 janelas foram classificadas corretamente. A Tabela V apresenta as

métricas individuais, enquanto a Fig. 2 exibe a matriz normalizada por classe real.

A classe Deitado alcançou precisão, revocação e F1 iguais a 1,000 nos 537 registros do teste. Os menores valores de F1 foram observados em Sentado (0,923) e Em pé (0,935). A principal confusão foi *Sentado → Em pé*, com 53 registros (10,8% das amostras sentadas), seguida por *Em pé → Sentado*, com 18 registros (3,4%). Também ocorreram erros de Subindo escadas para Caminhando (16) e Descendo escadas para Subindo escadas (15). A Tabela VI explicita as cinco confusões mais frequentes e suas direções, revelando que a maioria dos erros relevantes envolveu atividades semelhantes.

D. Importância das características no Random Forest

O modelo Random Forest treinado com os parâmetros selecionados produziu um ranking das 561 características. As

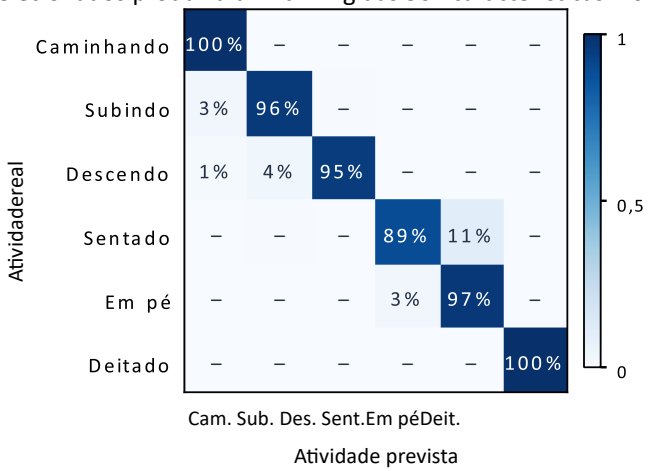


Figura 2. Matriz de confusão normalizada do SVM. Linhas: atividades reais; colunas: previstas.

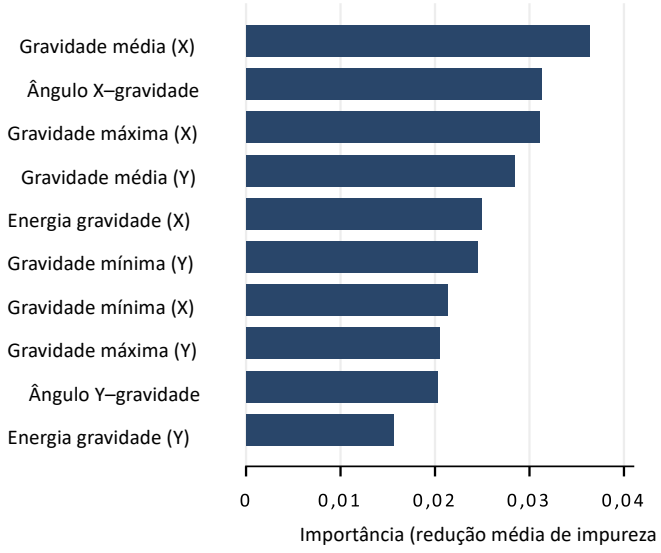


Figura 3. Dez características de maior importância global do Random Forest, medidas por redução média de impureza.

três de maior importância foram tGravityAcc-mean()-X (0,036370), angle(X,gravityMean) (0,031261) e tGravityAcc-max()-X (0,031093). A Fig. 3 resume as dez características mais importantes.

Entre os principais atributos estão estatísticas da aceleração gravitacional nos eixos X e Y e ângulos relacionados ao vetor médio da gravidade. Essa predominância sugere relevância de informações sobre orientação corporal nesse modelo, mas não informa qual variável causou uma classificação específica.

VI. Discussão

A. Desempenho preditivo e generalização

No conjunto de teste e nas configurações avaliadas, o SVM linear apresentou desempenho superior ao Random Forest em acurácia, precisão, revocação e F1 macro. Essa observação é compatível com a hipótese de que as características previamente extraídas do UCI HAR podem ser bem separadas por fronteiras lineares. Contudo, não demonstra superioridade geral do SVM em outras populações, sensores, bases de dados ou grades de parâmetros.

No SVM, a acurácia final de 96,17% foi superior à média de 93,27% da validação cruzada. Os grupos de participantes apresentam distribuições e dificuldades distintas; portanto, essa diferença não caracteriza, isoladamente, vazamento de dados. O protocolo separou indivíduos nas partições e não utilizou o teste oficial na escolha de parâmetros. Ao mesmo tempo, as métricas médias da validação cruzada devem ser interpretadas como resultados do procedimento de seleção, e não como estimativas estatisticamente independentes desse procedimento.

B. Erros específicos por atividade

A matriz de confusão revelou maior dificuldade em diferenciar Sentado de Em pé, duas classes estáticas. Embora a precisão da classe Sentado tenha sido 0,960, sua revocação foi 0,888, pois parte dos registros verdadeiros dessa classe foi reconhecida como Em pé. Uma possível explicação é a existência de padrões sensoriais semelhantes entre posturas estáticas em determinadas janelas; essa hipótese, entretanto, requer análise adicional dos sinais e distribuições de atributos.

Os bons resultados de Deitado não eliminam as diferenças entre classes. Por isso, as métricas macro e as matrizes de confusão complementam a acurácia agregada e permitem entender melhor o alcance prático dos classificadores.

C. Custo computacional e interpretação

O SVM apresentou menor tempo de ajuste final, enquanto o Random Forest apresentou menor tempo de predição, nas medições registradas. Como não houve repetição controlada dos tempos com intervalos de confiança, essa evidência não permite concluir que um algoritmo seja intrinsecamente mais rápido. Os valores também não incluem processamento bruto

de sinais, extração de atributos ou execução em dispositivo móvel.

No Random Forest, a importância por redução de impureza concentrou-se em atributos gravitacionais. Trata-se de uma medida global do conjunto de árvores, potencialmente influenciada por correlações entre características. Não deve ser interpretada como efeito causal ou relevância específica para uma única atividade; análises adicionais, como importância por permutação em amostras de validação, poderiam complementar o resultado.

D. Verificação da implementação

O código registra versões de bibliotecas, hiperparâmetros, partições, métricas e tempos em arquivos JSON/CSV, além de gráficos em PDF/PNG. Nas execuções reportadas, 35 testes da suíte integrada com unittest, quatro testes da matriz de confusão em pytest e dois testes da extração de importância em unittest passaram. Esses conjuntos foram executados em momentos distintos; não se trata de 41 testes realizados simultaneamente após o último merge. A análise de confusão reproduziu a acurácia salva no holdout. Tais verificações apoiam a reprodutibilidade, mas não equivalem a uma replicação integral e independente em diferentes máquinas.

VII. Ameaças à Validade

Validade interna. A separação por participante reduz o risco de vazamento de dados entre treinamento e validação. Os testes automatizados verificaram condições de separação e alinhamento das partições, e os hiperparâmetros finais foram recuperados de relatórios previamente salvos. Ainda assim, essas verificações não substituem uma auditoria independente de todos os artefatos e execuções.

Validade externa. O UCI HAR inclui 30 voluntários, seis atividades e uma coleta específica com smartphone na cintura. Consequentemente, os desempenhos observados não implicam que os modelos mantenham as mesmas métricas em outras faixas etárias, em dispositivos diferentes, com sensores posicionados em outros locais ou em ambientes menos controlados.

Validade de construto. As 561 entradas dos classificadores são atributos previamente extraídos dos sinais, e não janelas brutas processadas em tempo real pelos programas deste experimento. Os tempos informados descrevem apenas as etapas de ajuste e predição executadas, sem medir aquisição, transmissão, processamento bruto ou extração de características em um smartphone.

Validade estatística. As médias da validação cruzada são descritivas, e o holdout fornece uma avaliação final em um conjunto reservado. Não foram realizados testes formais de significância ou intervalos de confiança para a diferença de desempenho entre modelos. Os tempos também resultam de execuções pontuais, sem repetições padronizadas que permitam estimar sua variabilidade. Trabalhos futuros poderão investigar essas questões com protocolos específicos, evitando utilizar o conjunto de teste oficial para novas decisões de modelagem.

VIII. Conclusão

Este trabalho comparou SVM e Random Forest na classificação de seis atividades humanas do UCI HAR, com validação cruzada agrupada por participante, escolha de hiperparâmetros por F1 macro e avaliação final na partição oficial reservada. O SVM linear ($C = 0{,}1$) alcançou 96,17% de acurácia e 96,15% de F1 macro, enquanto o Random Forest (100 árvores, profundidade máxima 10, max_features=sqrt) obteve 92,40% e 92,17%, respectivamente.

A principal confusão do SVM foi entre Sentado e Em pé; no Random Forest, atributos associados à gravidade e à orientação estiveram entre os mais importantes. Assim, no protocolo experimental adotado, o SVM apresentou maior desempenho preditivo entre as configurações comparadas. Como trabalhos futuros, recomenda-se investigar outros participantes e posições de sensores, avaliar novas condições de coleta, examinar a estabilidade das importâncias e repetir medições de tempo sob condições controladas.

Referências

[1] D. Anguita, A. Ghio, L. Oneto, X. Parra, and J. L. Reyes-Ortiz, “A public domain dataset for human activity recognition using smartphones,” in *Proceedings of the European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN)*, Bruges, Belgium, 2013, pp. 437–442. [Online]. Available: https://hdl.handle.net/2117/20897

[2] J. L. Reyes-Ortiz, D. Anguita, A. Ghio, L. Oneto, and X. Parra, “Human activity recognition using smartphones,” UCI Machine Learning Repository, 2013. [Online]. Available: https://doi.org/10.24432/C54S4K

[3] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995. [Online]. Available: https://doi.org/10.1007/BF00994018

[4] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001. [Online]. Available: https://doi.org/10.1023/A:1010933404324

[5] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://www.jmlr.org/papers/v12/pedregosa11a.html

[6] Scikit-learn Developers, “GroupKFold — scikit-learn documentation,” [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html, 2026, accessed: Nov. 12, 2026.