Motion ID

Reconhecimento de atividades humanas com sensores de smartphone

Ryan Cassimiro · Wanessa Costa · Gustavo Lima · Ygor Gabriel

Esta proposta apresenta o problema de pesquisa, as perguntas, o conjunto de dados e os modelos previstos para o estudo. O objetivo é reconhecer atividades a partir de medidas de movimento e comparar a qualidade das previsões e o custo de processamento.

1 Problema de pesquisa

Um smartphone preso à cintura registra aceleração e rotação, mas esses registros não indicam diretamente o que a pessoa está fazendo. O problema é identificar seis atividades cotidianas a partir desses números, inclusive para pessoas que não participaram do treinamento dos modelos.

O estudo utilizará dados já coletados. Não serão utilizadas imagens, vídeos como entrada dos modelos nem coleta própria de movimentos.

2 Perguntas de pesquisa

1. Qual é o desempenho dos modelos no reconhecimento das seis atividades em participantes que não foram vistos durante o treinamento?
2. Entre SVM e Random Forest, qual apresenta melhores resultados, considerando os acertos e os tempos de treinamento e previsão?
3. Quais atividades são mais confundidas e quais medidas dos sensores ajudam a diferenciá-las?

3 Conjunto de dados

Será utilizado o *Human Activity Recognition Using Smartphones*, disponível no repositório UCI [1]. Os dados foram obtidos com 30 voluntários usando um smartphone Samsung Galaxy S II preso à cintura. O acelerômetro registra aceleração e o giroscópio registra velocidade de rotação, ambos em três direções.

Cada exemplo corresponde a uma janela de 2,56 segundos, com 561 medidas calculadas a partir dos sensores, como médias e variações. As janelas têm sobreposição de 50%. Cada exemplo possui também a atividade correta e a identificação do participante.

As seis atividades são: caminhar, subir escadas, descer escadas, estar sentado, ficar em pé e estar deitado.

Conjunto de dados e separação das amostras

Conjunto	Exemplos	Participantes
Treinamento	7.352	21
Teste	2.947	9
Total	10.299	30

Será preservada a divisão oficial: os participantes de teste são diferentes dos participantes de treinamento. A identificação da pessoa servirá apenas para organizar a avaliação, sem ser fornecida como informação para prever a atividade.

4 Modelos previstos e justificativas

SVM (máquina de vetores de suporte). Aprende a separar as atividades usando as medidas disponíveis. É uma escolha adequada para investigar conjuntos com muitas características numéricas e foi utilizada no estudo original do dataset [2]. As medidas serão padronizadas dentro do processo de treinamento.

Random Forest (floresta aleatória). Combina várias árvores de decisão para produzir uma previsão. Será comparada ao SVM por utilizar uma estratégia diferente e permitir investigar a importância das medidas dos sensores. Essa importância será interpretada como uma indicação do comportamento do modelo, sem estabelecer relações de causa e efeito.

Regressão Logística, opcional. Será considerada como uma referência mais simples para verificar se a complexidade dos modelos principais traz ganhos. Sua inclusão dependerá do tempo disponível. Os experimentos serão planejados para computadores pessoais, sem exigir uma placa de vídeo dedicada.

5 Avaliação planejada e limites

Os ajustes dos modelos serão escolhidos apenas dentro do conjunto de treinamento, mantendo pessoas diferentes nas partes usadas para aprender e validar. O conjunto de teste ficará reservado para a avaliação final, após a definição dos ajustes.

Serão reportados acurácia (proporção de acertos), precisão, recall e F1 com média entre as seis atividades, além de uma matriz de confusão para mostrar os erros e dos tempos de treinamento e previsão. Configurações, versões dos programas e condições de medição serão registradas para permitir a reprodução dos experimentos.

Esta etapa apresenta uma proposta, sem resultados experimentais concluídos. Os dados representam atividades em ambiente controlado e com o celular na cintura; o estudo não demonstrará desempenho para outras posições do aparelho ou situações de uso cotidiano.

Referências

[1] J. Reyes-Ortiz et al. *Human Activity Recognition Using Smartphones*. UCI Machine Learning Repository, 2013. DOI: 10.24432/C54S4K.

[2] D. Anguita et al. "A Public Domain Dataset for Human Activity Recognition Using Smartphones". *ESANN*, 2013, p. 437–442.